

# Méthodes de Monte–Carlo

## EISC-211

**Xavier Gendre & Jérôme Morio**

ISAE & ONERA

**2018–2019**

Très rapide aperçu des chaînes de Markov

But : Algorithme de Metropolis–Hastings

# Définition

## Chaîne de Markov $(X_t, t \geq 1)$

- ▶ Système dynamique **aléatoire**
- ▶ Innovation **indépendante du passé**

$$X_{t+1} = F(X_t, U_t), (U_t) \text{ i.i.d.}$$

# Utilité

## Modélisation de nombreux systèmes physiques

- ▶ L'évolution future ne dépend que de l'état actuel du système et pas de comment il y est arrivé
- ▶ Marchés financiers, séquences d'ADN, évolution de population, réseaux de communication, formation de cristaux, ...

## Algorithmes probabilistes

- ▶ Algorithmique
- ▶ Optimisation : recuit simulé
- ▶ Page Rank
- ▶ **Simulation**

# Propriété de Markov

## Définition

Un processus  $(X_t, t \geq 1)$  satisfait la propriété de Markov si le futur est indépendant du passé conditionnellement au présent, i.e., si

$$\begin{aligned}\mathbb{P}(X_{t+1} = x_{t+1} \mid X_t = x_t, X_{t-1} = x_{t-1}, \dots, X_0 = x_0) \\ = \mathbb{P}(X_{t+1} = x_{t+1} \mid X_t = x_t)\end{aligned}$$

## Analogie déterministe :

$\dot{x}(t) = F(x(t))$  et non  $\dot{x}(t) = F(x(s), s \leq t)$

## Théorème

$(X_t, t \geq 1)$  satisfait la propriété de Markov si et seulement on peut écrire

$$X_{t+1} = F(X_t, U_t), \quad (U_t) \text{ i.i.d.}$$

# Propriété de Markov

## Matrice de transition

La dynamique d'un processus de Markov  $(X_t)$  est donc caractérisée par la matrice de transition :

$$P = (p_{xy})_{x,y \in \mathcal{X}} \text{ avec } p_{xy} = \mathbb{P}(X_1 = y \mid X_0 = x)$$

# Convergence à l'équilibre

## Rappel

$(X_t)$  est une suite de variables aléatoires : elle peut donc converger **en loi**.

## Théorème

Si

$$\forall x, y \in \mathfrak{X} : \pi_x p_{xy} = \pi_y p_{yx}$$

alors  $X_t \xrightarrow[t \rightarrow +\infty]{L} \pi$ , i.e.,  $\mathbb{P}(X_t = x) \xrightarrow[t \rightarrow +\infty]{} \pi_x$  pour tout  $x \in \mathfrak{X}$ .

# Le cas i.i.d.

## Cas particulier

Si  $p_{xy} = p_y$ , i.e., l'état suivant ne dépend pas de la position courante, alors  $(X_t)$  est i.i.d. distribuée selon  $p = (p_x)_{x \in \mathcal{X}}$ .

- ▶ Loi des grands nombres
- ▶ Théorème central limite
- ▶ IIDMC

Ces deux résultats restent vrais dans le cas général !

- ▶ IIDMC  $\rightarrow$  MCMC



# Théorèmes de convergence

## Théorème ergodique

Si  $X_t \xrightarrow[t \rightarrow +\infty]{L} f + (\dots)$ , alors

$$\Phi_T = \frac{1}{T} \sum_{t=1}^T \phi(X_t) \xrightarrow[T \rightarrow +\infty]{p.s.} \mathbb{E}_f(\phi(X_1)) = \int \phi f.$$

## Théorème central limite

Si  $X_t \xrightarrow[t \rightarrow +\infty]{L} f + (\dots)$ , alors

$$\sqrt{T} \left( \Phi_T - \int \phi f \right) \xrightarrow[T \rightarrow +\infty]{L} N_f$$

où  $N_f$  suit une loi normale centrée de variance

$$\text{Var}_f(\phi(X_1)) + 2 \sum_{t \geq 2} \text{Cov}_\pi(\phi(X_1), \phi(X_t))$$

## Remarque

Cas i.i.d.  $\Rightarrow \text{Cov}_\pi(\phi(X_1), \phi(X_t)) = 0$

# Théorèmes de convergence

## Remarque

- ▶  $(X_t)$  i.i.d.  $\Rightarrow (\phi(X_t))$  i.i.d.
- ▶  $(X_t)$  MC  $\nRightarrow (\phi(X_t))$  MC !

# Résumé

## En résumé :

Si  $\pi_x p_{xy} = \pi_y p_{yx}(\star)$ , alors on a la loi des grands nombres et le TCL.

## Algorithme de Metropolis–Hastings

- ▶ Etant donné une distribution (densité) cible  $\pi$ , construction systématique d'une chaîne de Markov ( $P$ ) qui satisfait  $(\star)$
- ▶ Applications inombrables : biologie, physique, chimie, finances, fiabilité, traitement du signal, optimisation, EDP, vision par ordinateur, ...
- ▶ Très souvent **la seule** méthode disponible
- ▶ (A des défauts)